

Métodos de Penalización y Lagrangiano Aumentado

Oscar S. Dalmau Cedeño
dalmau@cimat.mx

22 de noviembre de 2018

1 Lagrangiano Aumentado

Lagrangiano Aumentado: restricciones de igualdad

Algoritmo o Framework para el Lagrangiano Aumentado

Propiedades

Lagrangiano Aumentado: restricciones de desigualdad

- El metodo del Lagrangiano aumentado este relacionado con los metodos de penalizacion.
- Este metodo intenta resolver el problema del mal condicionamiento que se presenta en los algoritmos de penalizacion: cuadraticos y de barrera

Motivacion: En el problema de optimizacion con restricciones de igualdad, la penalizacion cuadratica penaliza las restricciones que son violadas, ie, dado el problema de optimizacion, con restricciones de igualdad

$$\begin{array}{ll} \min & f(\mathbf{x}) \\ \text{s.t.} & c_i(\mathbf{x}) = 0, \ i \in \mathcal{E} \end{array}$$

La funcion de penalizacion cuadratica

$$Q(\mathbf{x}, \mu_k) = f(\mathbf{x}) + \frac{\mu_k}{2} \sum_{i \in \mathcal{E}} (c_i(\mathbf{x}))^2$$

Segun el teorema visto en clases, sobre la convergencia del Framework o algoritmo, las restricciones $c_i(\mathbf{x}_k) = 0$ no necesariamente se satisfacen para cada subproblema resuelto, y solo se obtiene una perturbacion, es decir, segun el teorema

$$\begin{aligned} \lambda_i^* &\approx -\mu_k c_i(\mathbf{x}_k) \\ c_i(\mathbf{x}_k) &\approx -\frac{\lambda_i}{\mu_k} \propto \frac{1}{\mu_k} \end{aligned}$$

- Es decir, $c_i(\mathbf{x}_k)$ es proporcional a $\frac{1}{\mu_k}$ y solo se garantiza que $c_i(\mathbf{x}_k) \rightarrow 0$ cuando $\mu_k \rightarrow \infty$.
- Lo anterior no es conveniente en alguno, pues en ocasiones nos gustaria que se satisficieran las restricciones de igualdad o al menos que se obtuviera una mejor aproximacion en un numero ‘moderado’ de iteraciones.

Lo anterior se puede lograr mediante la introducción de una nueva función, conocida como **Lagrangiano aumentado** que considera o es una combinación del Lagrangiano y el término de penalización, y se define como sigue:

$$\mathcal{L}_A(\mathbf{x}, \boldsymbol{\lambda}; \mu) \stackrel{\text{def}}{=} f(\mathbf{x}) - \sum_{i \in \mathcal{E}} \lambda_i c_i(\mathbf{x}) + \frac{\mu}{2} \sum_{i \in \mathcal{E}} (c_i(\mathbf{x}))^2$$

que es muy parecido al Lagrangiano, y solo se diferencia en el término de penalización.

$$\mathcal{L}(\mathbf{x}, \boldsymbol{\lambda}) = f(\mathbf{x}) - \sum_{i \in \mathcal{E}} \lambda_i c_i(\mathbf{x})$$

La idea ahora es desarrollar un algoritmo, similar a los de penalización en los que se resuelve una secuencia de subproblemas

$$\mathbf{x}_k = \arg \min_{\mathbf{x}} \mathcal{L}_A(\mathbf{x}, \boldsymbol{\lambda}^k; \mu_k)$$

donde los parámetros $\boldsymbol{\lambda} = \boldsymbol{\lambda}^k$ y $\mu = \mu_k$ son fijos en cada iteración. En la práctica, \mathbf{x}_k es solo un minimizador aproximado de $\mathcal{L}_A(\mathbf{x}, \boldsymbol{\lambda}^k; \mu_k)$.

- Para la actualización del parámetro de penalización μ_k se sigue la misma idea usada en penalización cuadrática, es decir, se selecciona una secuencia creciente y positiva, $0 < \mu_k < \mu_{k+1}$.
- Para el parámetro λ^k se comparan las condiciones de optimalidad del Lagrangiano y del Lagrangiano aumentado..

$$0 = \nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*) = \nabla f(\mathbf{x}^*) - \sum_{i \in \mathcal{E}} \lambda_i^* \nabla c_i(\mathbf{x}^*)$$

$$0 \approx \nabla_{\mathbf{x}} \mathcal{L}_A(\mathbf{x}_k, \boldsymbol{\lambda}^k; \mu_k) = \nabla f(\mathbf{x}_k) - \sum_{i \in \mathcal{E}} (\lambda_i^k - \mu_k c_i(\mathbf{x}_k)) \nabla c_i(\mathbf{x}_k)$$

Luego, comparando se tiene que:

$$\lambda_i^* \approx \lambda_i^k - \mu_k c_i(\mathbf{x}_k) \quad (1)$$

$$c_i(\mathbf{x}_k) \approx \frac{\lambda_i^k - \lambda_i^*}{\mu_k} \quad (2)$$

y si λ_i^k es lo suficientemente cercano a λ_i^* , entonces la no factibilidad de \mathbf{x}_k es menor a $\frac{1}{\mu_k}$, en lugar de ser proporcional a $\frac{1}{\mu_k}$ como en el caso de la penalización cuadrática.

Por otro lado, la relacion 1 sugiere una forma de actualizacion de λ^k es decir:

$$\lambda_i^{k+1} = \lambda_i^k - \mu_k c_i(\mathbf{x}_k) \quad (3)$$

Basado en lo anterior se tiene el siguiente algoritmo o esquema

Algorithm 1 Algoritmo de Lagrangiano Aumentado (restricciones de igualdad)

Dado un punto inicial x_0^s , λ^0 , $\tau_0, \mu_0 > 0$

for $k = 0, 1, 2, \dots$ **do**

Encontrar un minimizador aproximado x_k de $\mathcal{L}_A(x, \lambda^k; \mu_k)$ iniciando en x_k^s y se termina cuando $\|\nabla_x \mathcal{L}_A(x_k, \lambda; \mu_k)\| \leq \tau_k$

if converge **then**

Parar el algoritmo con solución x_k

end if

Actualizar $\lambda_i^{k+1} = \lambda_i^k - \mu_k c_i(x_k)$

Seleccionar $\mu_{k+1} > \mu_k$ y τ_{k+1}

Seleccionar un nuevo punto inicial x_{k+1}^s

end for

- El metodo converge sin necesidad de incrementar μ indefinidamente
- Debido a lo anterior se reduce el problema del mal condicionamiento, presente en los algoritmos de penalizacion
- El metodo es menos sensible a la selección del punto inicial x_{k+1}^s

Teorema

Sea x^ un minimo local del problema*

$$\begin{array}{ll} \min & f(x) \\ \text{s.a.} & c_i(x) = 0, \quad i \in \mathcal{E} \end{array}$$

Supongamos que gradientes $\nabla c_i(x^)$, $i \in \mathcal{E}$ son linealmente independientes (condicion LICQ). Si cumplen se las condiciones suficientes de segundo orden (Teorema 12.6), es decir, si se satisfacen las condiciones KKT del problema anterior para (x^*, λ^*) y si ademäs $\nabla_{xx}^2 \mathcal{L}(x^*, \lambda^*)$ es positivo definido en para $\omega \neq 0 \in \mathcal{C}(x^*, \lambda^*)$. Entonces existe un umbral $\hat{\mu}$ tal que para todo $\mu \geq \hat{\mu}$, x^* es un minimizador local de $\mathcal{L}_A(x, \lambda^*; \mu)$*

Nota:

$$\mathcal{F}(x) = \{d \mid d^T \nabla c_i(x) = 0, i \in \mathcal{E}; d^T \nabla c_i(x) \geq 0, i \in \mathcal{A}(x) \cap \mathcal{I}\}$$

$$\mathcal{C}(\mathbf{x}^*, \boldsymbol{\lambda}^*) = \{d \in \mathcal{F}(\mathbf{x}^*) \mid d^T \nabla c_i(\mathbf{x}^*) = 0, i \in \mathcal{A}(\mathbf{x}^*) \cap \mathcal{I}, \lambda_i^* > 0\}$$

$$d \in \mathcal{C}(\mathbf{x}^*, \boldsymbol{\lambda}^*) = \begin{cases} d^T \nabla c_i(\mathbf{x}^*) = 0, & i \in \mathcal{E} \\ d^T \nabla c_i(\mathbf{x}^*) = 0, & i \in \mathcal{A}(\mathbf{x}^*) \cap \mathcal{I}, \lambda_i^* > 0 \\ d^T \nabla c_i(\mathbf{x}^*) \geq 0, & i \in \mathcal{A}(\mathbf{x}^*) \cap \mathcal{I}, \lambda_i^* = 0 \end{cases}$$

- Primero se proba que si \mathbf{x}^* es un minimizador local del problema original, entonces es un punto critico de $\mathcal{L}_A(\mathbf{x}, \boldsymbol{\lambda}^*; \mu)$.
- Como \mathbf{x}^* es un minimizador local del problema original, entonces satisface las KKT's. Luego

$$\begin{aligned}\nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*) &= 0 \\ c_i(\mathbf{x}^*) &= 0, i \in \mathcal{E}\end{aligned}$$

Luego, evaluando el Lagrangiano aumentado en \mathbf{x}^* y usando las KKT's anteriores

$$\begin{aligned}
 \nabla_{\mathbf{x}} \mathcal{L}_A(\mathbf{x}^*, \boldsymbol{\lambda}^*; \mu) &= \nabla f(\mathbf{x}^*) - \sum_{i \in \mathcal{E}} \left(\lambda_i^* - \mu_k c_i(\mathbf{x}^*) \right) \nabla c_i(\mathbf{x}^*) \\
 &= \nabla f(\mathbf{x}^*) - \sum_{i \in \mathcal{E}} \lambda_i^* \nabla c_i(\mathbf{x}^*) \\
 &= \nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*) \\
 &= 0
 \end{aligned}$$

por lo que \mathbf{x}^* es un punto critico de $\mathcal{L}_A(\mathbf{x}, \boldsymbol{\lambda}^*; \mu)$, independientemente del valor de μ

- Ahora se proba que es un minimo local, es decir, hay que probar que $\mathcal{L}_A(\mathbf{x}^*, \boldsymbol{\lambda}^*; \mu)$ es positiva definida.. Para ello se usara reduccion al absurdo!.
- Supongamos $\nabla_{\mathbf{x}\mathbf{x}}^2 \mathcal{L}_A(\mathbf{x}^*, \boldsymbol{\lambda}^*; \mu)$ no es positiva definida, entonces existe $\omega \neq 0$ tal que

$$\omega^T \nabla_{\mathbf{x}\mathbf{x}}^2 \mathcal{L}_A(\mathbf{x}^*, \boldsymbol{\lambda}^*; \mu) \omega \leq 0$$

$$\begin{aligned}\nabla_{\mathbf{x}\mathbf{x}}^2 \mathcal{L}_A(\mathbf{x}^*, \boldsymbol{\lambda}^*; \mu) &= \nabla_{\mathbf{x}\mathbf{x}}^2 \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*) + \mu \sum_{i \in \mathcal{E}} c_i(\mathbf{x}^*) \nabla_{\mathbf{x}\mathbf{x}}^2 c_i(\mathbf{x}^*) \\ &\quad + \nabla c_i(\mathbf{x}^*) \nabla c_i(\mathbf{x}^*)^T \\ &= \nabla_{\mathbf{x}\mathbf{x}}^2 \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*) + \mu A^T A\end{aligned}$$

con $A^T = [\nabla c_1(\mathbf{x}^*), \dots, \nabla c_{|\mathcal{E}|}(\mathbf{x}^*)]$.

Entonces

$$\begin{aligned}\omega^T (\nabla_{xx}^2 \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*) + \mu AA^T) \omega &\leq 0 \\ \|A\omega\|^2 &\leq -\frac{1}{\mu} \omega^T \nabla_{xx}^2 \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*) \omega\end{aligned}$$

haciendo tender $\mu \rightarrow \infty$ se tiene

$$\|A\omega\|^2 \leq 0$$

Luego $A\omega = 0$, ie, $\nabla c_i(\mathbf{x}^*)^T \omega = 0$, $i \in \mathcal{E}$ y por tanto
 $\omega \in \mathcal{C}(\mathbf{x}^*, \boldsymbol{\lambda}^*)$

Como $\omega \in \mathcal{C}(\mathbf{x}^*, \boldsymbol{\lambda}^*)$ y por tanto $A\omega = 0$ entonces

$$\begin{aligned}
 0 &\geq \omega^T \nabla_{\mathbf{x}\mathbf{x}}^2 \mathcal{L}_A(\mathbf{x}^*, \boldsymbol{\lambda}^*; \mu) \omega \\
 &= \omega^T (\nabla_{\mathbf{x}\mathbf{x}}^2 \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*) + \mu A A^T) \omega \\
 &= \omega^T \nabla_{\mathbf{x}\mathbf{x}}^2 \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*) \omega + \mu \underbrace{\|A\omega\|^2}_{=0}
 \end{aligned}$$

Luego

$$\omega^T \nabla_{xx}^2 \mathcal{L}(x^*, \lambda^*) \omega \leq 0$$

Lo que es una contradicción con las condiciones de segundo orden, ie, pues $\nabla_{xx}^2 \mathcal{L}(x^*, \lambda^*)$ es positiva definida en $\mathcal{C}(x^*, \lambda^*)$, con x^* un mínimo local del problema original.

Problema de optimizacion

$$\begin{array}{ll} \min_{\boldsymbol{x}} & f(\boldsymbol{x}) \\ \text{s.a.} & c_i(\boldsymbol{x}) \geq 0, \ i \in \mathcal{I} \end{array}$$

Para usar el metodo del Lagrangiano Aumentado, se introducen variables de holguras, de este modo se obtiene el siguiente problema:

$$\begin{aligned} & \min_{\mathbf{x}, \mathbf{s}} f(\mathbf{x}) \\ \text{s.a.} \quad & c_i(\mathbf{x}) - s_i = 0, \quad i \in \mathcal{I} \\ & s_i \geq 0, \quad i \in \mathcal{I} \end{aligned}$$

Ahora podemos calcular el Lagrangiano aumentado, solo para las restricciones de igualdad, y tenemos el siguiente problema:

$$\begin{aligned} \min_{\mathbf{x}, \mathbf{s}} \mathcal{L}_A(\mathbf{x}, \boldsymbol{\lambda}^k; \mu_k) &= f(\mathbf{x}) - \sum_{i \in \mathcal{I}} \lambda_i^k (c_i(\mathbf{x}) - s_i) + \frac{\mu_k}{2} \sum_{i \in \mathcal{I}} (c_i(\mathbf{x}) - s_i)^2 \\ s_i &\geq 0, \quad i \in \mathcal{I} \end{aligned}$$

Ahora podemos resolver el problema de optimización, respecto a \mathbf{x} , s y luego es posible eliminar la variable de holgura s usando un método de proyección.

$$\partial_{s_i} \mathcal{L}_A(\mathbf{x}, \boldsymbol{\lambda}^k; \mu_k) = \lambda_i^k - \mu_k(c_i(\mathbf{x}) - s_i) = 0 \quad (4)$$

$$s_i = c_i(\mathbf{x}) - \frac{\lambda_i^k}{\mu_k}. \quad (5)$$

es decir

$$s_i = \begin{cases} c_i(\mathbf{x}) - \frac{\lambda_i^k}{\mu_k} & \text{si } c_i(\mathbf{x}) - \frac{\lambda_i^k}{\mu_k} \geq 0, (\text{ ó } \lambda_i^k \leq \mu_k c_i(\mathbf{x})) \\ 0 & \text{si } c_i(\mathbf{x}) - \frac{\lambda_i^k}{\mu_k} < 0, (\text{ ó } \lambda_i^k > \mu_k c_i(\mathbf{x})) \end{cases}$$

Luego (el signo igual de la comparación puede estar en cualquiera de la opciones, pero se ubica con el signo ' $<$ ' convenientemente)

- Si $c_i(\mathbf{x}) - \frac{\lambda_i^k}{\mu_k} > 0$, entonces $c_i(\mathbf{x}) - s_i = \frac{\lambda_i^k}{\mu_k}$

$$\begin{aligned}
 & - \sum_{i \in \mathcal{I}} \lambda_i^k (c_i(\mathbf{x}) - s_i) + \frac{\mu_k}{2} \sum_{i \in \mathcal{I}} (c_i(\mathbf{x}) - s_i)^2 \\
 = & - \sum_{i \in \mathcal{I}} \lambda_i^k \frac{\lambda_i^k}{\mu_k} + \frac{\mu_k}{2} \sum_{i \in \mathcal{I}} \left(\frac{\lambda_i^k}{\mu_k} \right)^2 \\
 = & - \frac{1}{2} \sum_{i \in \mathcal{I} | c_i(\mathbf{x}) - \frac{\lambda_i^k}{\mu_k} > 0} \frac{(\lambda_i^k)^2}{\mu_k}
 \end{aligned}$$

- Si $c_i(\mathbf{x}) - \frac{\lambda_i^k}{\mu_k} \leq 0$, entonces $s_i = 0$

$$\begin{aligned}
 & - \sum_{i \in \mathcal{I}} \lambda_i^k (c_i(\mathbf{x}) - s_i) + \frac{\mu_k}{2} \sum_{i \in \mathcal{I}} (c_i(\mathbf{x}) - s_i)^2 \\
 = & \sum_{i \in \mathcal{I} | c_i(\mathbf{x}) - \frac{\lambda_i^k}{\mu_k} \leq 0} -\lambda_i^k c_i(\mathbf{x}) + \frac{\mu_k}{2} (c_i(\mathbf{x}))^2
 \end{aligned}$$

Basado en los casos anteriores, el Lagrangiano Aumentado se puede escribir como sigue

$$\begin{aligned}
 \mathcal{L}_A(\mathbf{x}, \boldsymbol{\lambda}^k; \mu_k) &= \nabla f(\mathbf{x}) + \sum_{i \in \mathcal{I} | c_i(\mathbf{x}) - \frac{\lambda_i^k}{\mu_k} \leq 0} -\lambda_i^k c_i(\mathbf{x}) + \frac{\mu_k}{2} (c_i(\mathbf{x}))^2 \\
 &\quad - \frac{1}{2} \sum_{i \in \mathcal{I} | c_i(\mathbf{x}) - \frac{\lambda_i^k}{\mu_k} > 0} \frac{(\lambda_i^k)^2}{\mu_k}
 \end{aligned}$$

- En la practica usamos un metodo iterativo para estimar el optimo x_k del subproblema.
- En cada iteracion se deben garantizar las restricciones $s_i \geq 0$, para lo cual se usa un metodo de proyeccion (iterativo).
- Conocidos $(x_k, \lambda_i^k, \mu_k)$ en la iteracion actual, ie, x_k corresponde al valor actual durante el proceso iterativo y λ_i^k, μ_k son fijos, se identifican el las $s_i < 0$ (que dependen de $(x_k, \lambda_i^k, \mu_k)$ segun (5)) y se proyectan a 0,

Finalmente, el subproblema para el Lagrangiano Aumentado se puede escribir como sigue:

$$\begin{aligned}\mathcal{L}_A(\mathbf{x}, \boldsymbol{\lambda}^k; \mu_k) &:= \nabla f(\mathbf{x}) + \sum_{i \in \mathcal{I} | c_i(\mathbf{x}_k) - \frac{\lambda_i^k}{\mu_k} \leq 0} -\lambda_i^k c_i(\mathbf{x}) + \frac{\mu_k}{2} (c_i(\mathbf{x}))^2 \\ &\quad - \frac{1}{2} \sum_{i \in \mathcal{I} | c_i(\mathbf{x}_k) - \frac{\lambda_i^k}{\mu_k} > 0} \frac{(\lambda_i^k)^2}{\mu_k}\end{aligned}$$

$$\mathbf{x}_{k+1} = \arg \min_{\mathbf{x}} \mathcal{L}_A(\mathbf{x}, \boldsymbol{\lambda}^k; \mu_k)$$

Que se puede escribir de forma compacta, si se define la funcion

$$\Psi(a, b, c) = \begin{cases} -ba + \frac{c}{2}a^2 & \text{si } a - \frac{b}{c} \leq 0, \\ -\frac{b^2}{2c} & \text{si } a - \frac{b}{c} > 0 \end{cases}$$

y se obtiene simplemente

$$\begin{aligned}\mathcal{L}_A(\mathbf{x}, \boldsymbol{\lambda}^k; \mu_k) &= f(\mathbf{x}) + \sum_{i \in \mathcal{I}} \Psi(c_i(\mathbf{x}), \lambda_i^k, \mu_k) \\ \nabla \mathcal{L}_A(\mathbf{x}, \boldsymbol{\lambda}^k; \mu_k) &= \nabla f(\mathbf{x}) + \sum_{i \in \mathcal{I}} \nabla \Psi(c_i(\mathbf{x}), \lambda_i^k, \mu_k) \\ &= \nabla f(\mathbf{x}) + \sum_{i \in \mathcal{I} | c_i(\mathbf{x}_k) - \frac{\lambda_i^k}{\mu_k} \leq 0} (-\lambda_i^k + \mu_k c_i(\mathbf{x})) \nabla c_i(\mathbf{x})\end{aligned}$$

- Para actualizar los λ_i^k en la próxima iteración, suponemos que se ha calculado el óptimo x_k en el problema actual.
- Ahora podemos comparar el gradiente del Lagrangiano con el gradiente del Lagrangiano aumentado evaluados en los óptimos x^* , x_k del problema original y del subproblema respectivamente,

es decir

$$\begin{aligned}
 \nabla \mathcal{L}_A(\mathbf{x}_k, \boldsymbol{\lambda}^k; \mu_k) &= \nabla f(\mathbf{x}_k) - \sum_{i \in \mathcal{I} | c_i(\mathbf{x}_k) - \frac{\lambda_i^k}{\mu_k} > 0} 0 \\
 &\quad + \sum_{i \in \mathcal{I} | c_i(\mathbf{x}_k) - \frac{\lambda_i^k}{\mu_k} \leq 0} (-\lambda_i^k + \mu_k c_i(\mathbf{x}_k)) \nabla c_i(\mathbf{x}_k) \\
 \nabla \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*) &= \nabla f(\mathbf{x}^*) - \sum_{i \in \mathcal{I} | c_i(\mathbf{x}^*) \leq 0} \lambda_i^* \nabla c_i(\mathbf{x}^*) \\
 &\quad - \sum_{i \in \mathcal{I} | c_i(\mathbf{x}^*) > 0} \cancel{\lambda_i^*} \nabla c_i(\mathbf{x}^*) \quad 0, \text{ pues } \lambda_i^* c_i(\mathbf{x}^*) = 0
 \end{aligned}$$

Haciendo la comparacion

$$\lambda_i^* \approx \begin{cases} \lambda_i^k - \mu_k c_i(\mathbf{x}_k) & \text{si } c_i(\mathbf{x}_k) - \frac{\lambda_i^k}{\mu_k} \leq 0 \\ 0 & \text{si } c_i(\mathbf{x}_k) - \frac{\lambda_i^k}{\mu_k} > 0 \end{cases} \quad (6)$$

$$\lambda_i^{k+1} = \begin{cases} \lambda_i^k - \mu_k c_i(\mathbf{x}_k) & \text{si } c_i(\mathbf{x}_k) - \frac{\lambda_i^k}{\mu_k} \leq 0 \\ 0 & \text{si } c_i(\mathbf{x}_k) - \frac{\lambda_i^k}{\mu_k} > 0 \end{cases} \quad (7)$$

$$\lambda_i^{k+1} = \max(0, \lambda_i^k - \mu_k c_i(\mathbf{x}_k)) \quad (8)$$

Algorithm 2 Algoritmo de Lagrangiano Aumentado (restricciones de desigualdad)

Dado un punto inicial x_0^s , λ^0 , $\tau_0, \mu_0 > 0$

for $k = 0, 1, 2, \dots$ **do**

Encontrar un minimizador aproximado x_k de $\mathcal{L}_A(x, \lambda^k; \mu_k)$
iniciando en x_k^s y se termina cuando $\|\nabla_x \mathcal{L}_A(x_k, \lambda^k; \mu_k)\| \leq \tau_k$

if converge **then**

Parar el algoritmo con solución x_k

end if

Actualizar $\lambda_i^{k+1} = \max(0, \lambda_i^k - \mu_k c_i(x_k))$

Seleccionar $\mu_{k+1} > \mu_k$

Seleccionar τ_{k+1}

Seleccionar un nuevo punto inicial x_{k+1}^s

end for