

Programacion Cuadratica Secuencial

Oscar S. Dalmau Cedeño
dalmau@cimat.mx

15 de noviembre de 2018

- 1 SQP con restricciones de igualdad
Metodo SQP local
SQP Framework
- 2 SQP con restricciones de igualdad y desigualdad
- 3 Cuasi Newton para SQP: Damped BFGS

Dado el problema con restricciones de igualdad:

$$\text{mín } f(\mathbf{x}) \tag{1}$$

$$s.a. : c_i(\mathbf{x}) = 0, i \in \mathcal{E} \tag{2}$$

Calculemos su Lagrangiano y las condiciones KKTs correspondientes.

$$\mathcal{L}(\mathbf{x}, \boldsymbol{\lambda}) = f(\mathbf{x}) - \boldsymbol{\lambda}^T \mathbf{c}(\mathbf{x}) \quad (3)$$

donde $\mathbf{c}(\mathbf{x}) \stackrel{\text{def}}{=} [c_i(\mathbf{x})]_{i \in \mathcal{E}} \in \mathbb{R}^{|\mathcal{E}|}$. Luego

$$\nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \boldsymbol{\lambda}) = \nabla f(\mathbf{x}) - \nabla \mathbf{c}(\mathbf{x}) \boldsymbol{\lambda} = \mathbf{0} \quad (4)$$

$$\mathbf{c}(\mathbf{x}) = \mathbf{0} \quad (5)$$

donde $\nabla \mathbf{c}(\mathbf{x}) = [\nabla c_i(\mathbf{x})]_{i \in \mathcal{E}} \in \mathbb{R}^{n \times |\mathcal{E}|} \stackrel{\text{def}}{=} \mathbf{A}(\mathbf{x})^T$.

Ahora podemos usar el metodo de Newton para resolver el problema

$$F(\mathbf{x}, \boldsymbol{\lambda}) = \mathbf{0} \quad (6)$$

donde

$$\begin{aligned} F(\mathbf{x}, \boldsymbol{\lambda}) &= \begin{bmatrix} \nabla_x \mathcal{L}(\mathbf{x}, \boldsymbol{\lambda}) \\ \mathbf{c}(\mathbf{x}) \end{bmatrix} \\ &= \begin{bmatrix} \nabla f(\mathbf{x}) - \nabla \mathbf{c}(\mathbf{x}) \boldsymbol{\lambda} \\ \mathbf{c}(\mathbf{x}) \end{bmatrix} \\ &= \begin{bmatrix} \nabla f(\mathbf{x}) - \mathbf{A}(\mathbf{x})^T \boldsymbol{\lambda} \\ \mathbf{c}(\mathbf{x}) \end{bmatrix} \end{aligned}$$

Se resuelve el siguiente sistema con respecto a $[p_k^x; p_k^\lambda]$

$$F'(x_k, \lambda_k) \begin{bmatrix} p_k^x \\ p_k^\lambda \end{bmatrix} = -F(x_k, \lambda_k) \quad (7)$$

Luego, se tiene el siguiente esquema iterativo (Newton)

$$\begin{bmatrix} \mathbf{x}_{k+1} \\ \boldsymbol{\lambda}_{k+1} \end{bmatrix} = \begin{bmatrix} \mathbf{x}_k \\ \boldsymbol{\lambda}_k \end{bmatrix} + \begin{bmatrix} \mathbf{p}_k^x \\ \mathbf{p}_k^\lambda \end{bmatrix} \quad (8)$$

$$F'(\mathbf{x}_k, \boldsymbol{\lambda}_k) \begin{bmatrix} \mathbf{p}_k^x \\ \mathbf{p}_k^\lambda \end{bmatrix} = -F(\mathbf{x}_k, \boldsymbol{\lambda}_k) \quad (9)$$

$$\begin{bmatrix} \nabla_{\mathbf{x}\mathbf{x}}^2 \mathcal{L}(\mathbf{x}_k, \boldsymbol{\lambda}_k) & -\mathbf{A}(\mathbf{x}_k)^T \\ \mathbf{A}(\mathbf{x}_k) & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{p}_k^x \\ \mathbf{p}_k^\lambda \end{bmatrix} = - \begin{bmatrix} \nabla f(\mathbf{x}_k) - \mathbf{A}(\mathbf{x}_k)^T \boldsymbol{\lambda}_k \\ \mathbf{c}(\mathbf{x}_k) \end{bmatrix}$$

Definiendo

$$f_k \stackrel{\text{def}}{=} f(\mathbf{x}_k) \quad (10)$$

$$\nabla f_k \stackrel{\text{def}}{=} \nabla f(\mathbf{x}_k) \quad (11)$$

$$\mathcal{L}_k \stackrel{\text{def}}{=} \mathcal{L}(\mathbf{x}_k, \boldsymbol{\lambda}_k) \quad (12)$$

$$\nabla_{\mathbf{x}} \mathcal{L}_k \stackrel{\text{def}}{=} \nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}_k, \boldsymbol{\lambda}_k) \quad (13)$$

$$\nabla_{\mathbf{x}\mathbf{x}}^2 \mathcal{L}_k \stackrel{\text{def}}{=} \nabla_{\mathbf{x}\mathbf{x}}^2 \mathcal{L}(\mathbf{x}_k, \boldsymbol{\lambda}_k) \quad (14)$$

$$\mathbf{c}_k \stackrel{\text{def}}{=} \mathbf{c}(\mathbf{x}_k) \quad (15)$$

$$\mathbf{A}_k^T \stackrel{\text{def}}{=} \mathbf{A}(\mathbf{x}_k)^T \stackrel{\text{def}}{=} [\nabla c_i(\mathbf{x}_k)]_{i \in \mathcal{E}} \quad (16)$$

$$\begin{bmatrix} \nabla_{xx}^2 \mathcal{L}_k & -\mathbf{A}_k^T \\ \mathbf{A}_k & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{p}_k^x \\ \mathbf{p}_k^\lambda \end{bmatrix} = - \begin{bmatrix} \nabla f_k - \mathbf{A}_k^T \boldsymbol{\lambda}_k \\ \mathbf{c}_k \end{bmatrix} \quad (17)$$

Supuestos

- 1 El jacobiano de las restricciones $\mathbf{A}(x)$ tiene rango completo
- 2 La matriz $\mathcal{L}(x, \lambda)$ es positiva definida en el espacio tangente de las restricciones, ie, $d^T \nabla_{xx}^2 \mathcal{L}(x, \lambda) d > 0$ para toda $d \neq 0$ tal que $\mathbf{A}(x)d = 0$

Recordatorio: Karush-Kuhn-Tucker matrix

Lemma

Let \mathbf{A} have full row rank, and assume that the reduced Hessian matrix $\mathbf{Z}^T \mathbf{G} \mathbf{Z}$ is positive definite. Then the KKT matrix

$$\mathbf{K} = \begin{bmatrix} \mathbf{G} & \mathbf{A}^T \\ \mathbf{A} & 0 \end{bmatrix} \quad (18)$$

is nonsingular, and hence there is a unique vector pair $(\mathbf{x}^*, \lambda^*)$ satisfying the KKT conditions.

Here $\mathbf{Z} \in \mathbb{R}^{n \times (n-m)}$ is a matrix whose columns are a basis for the null space of \mathbf{A} . That is, \mathbf{Z} has full rank and satisfies $\mathbf{A} \mathbf{Z} = 0$.

SQP Framework

$$\begin{bmatrix} \nabla_{xx}^2 \mathcal{L}_k & -\mathbf{A}_k^T \\ \mathbf{A}_k & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{p}_k^x \\ \mathbf{p}_k^\lambda \end{bmatrix} = - \begin{bmatrix} \nabla f_k - \mathbf{A}_k^T \boldsymbol{\lambda}_k \\ \mathbf{c}_k \end{bmatrix} \quad (19)$$

$$\begin{bmatrix} \nabla_{xx}^2 \mathcal{L}_k & -\mathbf{A}_k^T \\ \mathbf{A}_k & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{p}_k^x \\ \boldsymbol{\lambda}_k + \mathbf{p}_k^\lambda \end{bmatrix} = - \begin{bmatrix} \nabla f_k \\ \mathbf{c}_k \end{bmatrix} \quad (20)$$

$$\begin{bmatrix} \nabla_{xx}^2 \mathcal{L}_k & -\mathbf{A}_k^T \\ \mathbf{A}_k & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{p}_k^x \\ \boldsymbol{\lambda}_{k+1} \end{bmatrix} = - \begin{bmatrix} \nabla f_k \\ \mathbf{c}_k \end{bmatrix} \quad (21)$$

El sistema anterior se puede escribir como sigue

$$\begin{bmatrix} \nabla_{xx}^2 \mathcal{L}_k & -\mathbf{A}_k^T \\ \mathbf{A}_k & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{p}_k^x \\ l_k \end{bmatrix} = - \begin{bmatrix} \nabla f_k \\ \mathbf{c}_k \end{bmatrix} \quad (22)$$

El sistema anterior se puede ver con las KKTs de un problema cuadrático, donde $\hat{\mathcal{L}}_k(\mathbf{p}, l)$ es el Lagrangiano correspondiente

$$\nabla_{\mathbf{p}} \hat{\mathcal{L}}_k(\mathbf{p}, l) = \nabla_{\mathbf{xx}}^2 \mathcal{L}_k \mathbf{p} + \nabla f_k - \mathbf{A}_k^T l = \mathbf{0} \quad (23)$$

$$\mathbf{A}_k \mathbf{p} + \mathbf{c}_k = \mathbf{0} \quad (24)$$

luego

$$\hat{\mathcal{L}}_k(\mathbf{p}, l) = \frac{1}{2} \mathbf{p}^T \nabla_{xx}^2 \mathcal{L}_k \mathbf{p} + \nabla f_k^T \mathbf{p} - l^T (\mathbf{A}_k \mathbf{p} + \mathbf{c}_k) \quad (25)$$

$$\mathbf{A}_k \mathbf{p} + \mathbf{c}_k = \mathbf{0} \quad (26)$$

que conduce al problema cuadrático equivalente

$$\mathbf{p}_k = \arg \min_{\mathbf{p}} \frac{1}{2} \mathbf{p}^T \nabla_{\mathbf{x}\mathbf{x}}^2 \mathcal{L}_k \mathbf{p} + \nabla f_k^T \mathbf{p} \quad (27)$$

$$s.a : \mathbf{A}_k \mathbf{p} + \mathbf{c}_k = \mathbf{0} \quad (28)$$

o lo que es lo mismo

$$\mathbf{p}_k = \arg \min_{\mathbf{p}} \frac{1}{2} \mathbf{p}^T \nabla_{\mathbf{x}\mathbf{x}}^2 \mathcal{L}_k \mathbf{p} + \nabla f_k^T \mathbf{p} \quad (29)$$

$$s.a : \nabla c_i(\mathbf{x}_k)^T \mathbf{p} + c_i(\mathbf{x}_k) = 0, \quad i \in \mathcal{E} \quad (30)$$

y si l_k son los multiplicadores de Lagrange del problema anterior, entonces $\lambda_{k+1} = l_k$.

Por otro lado,

$$\nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \boldsymbol{\lambda}) = \nabla f(\mathbf{x}) - \mathbf{A}(\mathbf{x})^T \boldsymbol{\lambda} \quad (31)$$

en el punto $\mathbf{x}_k, \boldsymbol{\lambda}_k$ cumple

$$\nabla_{\mathbf{x}} \mathcal{L}_k \mathbf{p} = (\nabla f_k - \mathbf{A}_k^T \boldsymbol{\lambda}_k)^T \mathbf{p} \quad (32)$$

$$= \nabla f_k^T \mathbf{p} - \boldsymbol{\lambda}_k^T \mathbf{A}_k^T \mathbf{p} \quad (33)$$

como $\mathbf{A}_k^T \mathbf{p} = -\mathbf{c}_k$ entonces

$$\nabla_{\mathbf{x}} \mathcal{L}_k^T \mathbf{p} = \nabla f_k^T \mathbf{p} + \boldsymbol{\lambda}_k^T \mathbf{c}_k \quad (34)$$

y como $\lambda_k^T c_k$ es una constante, entonces el problema (27)-(28) es equivalente a

$$p_k = \arg \min_p q(p) = \frac{1}{2} p^T \nabla_{xx}^2 \mathcal{L}_k p + \nabla_x \mathcal{L}_k^T p \quad (35)$$

$$s.a : A_k p + c_k = 0 \quad (36)$$

donde $\lambda_{k+1} = l_k$ y l_k son los multiplicadores del Lagrange del problema anterior.

Algorithm 1 Algoritmo SQP con restricciones de igualdad

Dado x_0, λ_0

for $k = 0, 1, 2, \dots$ (Hasta Convergencia) **do**

Hallar $\nabla_{xx}^2 \mathcal{L}_k, \nabla \mathcal{L}_k, \mathbf{A}_k, c_k$, segun (10)-(16)

Obtener p_k, l_k , resolviendo (35)-(36) o el equivalente (27)-(28)

Actualizar $x_{k+1} = x_k + p_k$

Actualizar $\lambda_{k+1} = l_k$

end for

El algoritmo se puede ver de la siguiente forma:

- 1 Se obtiene la aproximacion cuadratica del Lagrangiano alrededor de x_k con λ_k fijo ie,

$$\mathcal{L}(x_k + p, \lambda_k) \approx \frac{1}{2}p^T \nabla_{xx}^2 \mathcal{L}_k p + \nabla_x \mathcal{L}_k^T p + \mathcal{L}_k \quad (37)$$

- 2 Se obtiene la aproximacion lineal de las restricciones,

$$c(x_k + p) \approx A_k^T p + c_k \quad (38)$$

$$\text{mín } f(\mathbf{x}) \tag{39}$$

$$s.a. : c_i(\mathbf{x}) = 0, i \in \mathcal{E} \tag{40}$$

$$c_i(\mathbf{x}) \geq 0, i \in \mathcal{I} \tag{41}$$

Para este problema se sigue el mismo esquema anterior,

es decir, se obtiene el paso \mathbf{p}_k minimizando la aproximación cuadrática del Lagrangiano en \mathbf{x}_k , sujeto a la aproximación lineal de las restricciones, esto es:

$$\mathbf{p}_k = \arg \min_{\mathbf{p}} \frac{1}{2} \mathbf{p}^T \nabla_{\mathbf{x}\mathbf{x}}^2 \mathcal{L}_k \mathbf{p} + \nabla f_k^T \mathbf{p} \quad (42)$$

$$s.a : \nabla c_i(\mathbf{x}_k)^T \mathbf{p} + c_i(\mathbf{x}_k) = 0, \quad i \in \mathcal{E} \quad (43)$$

$$\nabla c_i(\mathbf{x}_k)^T \mathbf{p} + c_i(\mathbf{x}_k) \geq 0, \quad i \in \mathcal{I} \quad (44)$$

y si l_k son los multiplicadores de Lagrange del problema anterior, entonces $\lambda_{k+1} = l_k$.

Para resolver el subproblema (42)-(44) se puede usar el **metodo de conjuntos activos**.

Teorema

Suponga que x^* es una solución del problema de optimización con restricciones de igualdad y desigualdad y se cumplen las KKTs para algún λ^* . Suponga que se cumplen las LICQ, las restricciones de complementariedad estrictas y las condiciones suficientes de segundo orden en (x^*, λ^*) . Entonces, si (x_k, λ_k) es suficientemente cercano a (x^*, λ^*) entonces existe una solución local del subproblema cuadrático cuyo conjunto activo A_k es el mismo que el conjunto activo $A(x^*)$ del problema no lineal en el punto x^* .

Damped BFGS

En muchas aplicaciones no es facil acceder o calcular $\nabla_{xx}^2 \mathcal{L}_k$.
En este caso se sugiere usar el metodo **cuasi Newton BFGS**
para aproximar el Hessiano,

$$\mathbf{B}_k \approx \nabla_{xx}^2 \mathcal{L}_k$$

en funcion de los gradiente, es decir,

$$\begin{aligned} \mathbf{s}_k &= \mathbf{x}_{k+1} - \mathbf{x}_k \\ \mathbf{y}_k &= \nabla_{\mathbf{x}} \mathcal{L}_{k+1} - \nabla_{\mathbf{x}} \mathcal{L}_k \\ \mathbf{B}_{k+1} &= \mathbf{B}_k - \frac{\mathbf{B}_k \mathbf{s}_k \mathbf{s}_k^T \mathbf{B}_k}{\mathbf{s}_k^T \mathbf{B}_k \mathbf{s}_k} + \frac{\mathbf{y}_k^T \mathbf{y}_k}{\mathbf{s}_k^T \mathbf{y}_k} \end{aligned}$$

satisfaciendo la condicion de curvatura $\mathbf{s}_k^T \mathbf{y}_k > 0$.

Dado que la condicion de curvatura no se puede garantizar que se cumpla, se propone actualizar \mathbf{B}_{k+1} usando BFGS si la condicion de curvatura es suficientemente positiva, es decir, si

$$\mathbf{s}_k^T \mathbf{y}_k \geq \theta \mathbf{s}_k^T \mathbf{B}_k \mathbf{s}_k$$

donde $\theta \in [0, 1]$ es un parametro, por ejemplo $\theta = 0,2$.

En otro caso, se propone usar una combinación lineal

$$\begin{aligned} \mathbf{s}_k &= \mathbf{x}_{k+1} - \mathbf{x}_k \\ \mathbf{y}_k &= \nabla_{\mathbf{x}} \mathcal{L}_{k+1} - \nabla_{\mathbf{x}} \mathcal{L}_k \\ \mathbf{r}_k &= \theta_k \mathbf{y}_k + (1 - \theta_k) \mathbf{B}_k \mathbf{s}_k \\ \mathbf{B}_{k+1} &= \mathbf{B}_k - \frac{\mathbf{B}_k \mathbf{s}_k \mathbf{s}_k^T \mathbf{B}_k}{\mathbf{s}_k^T \mathbf{B}_k \mathbf{s}_k} + \frac{\mathbf{r}_k^T \mathbf{r}_k}{\mathbf{s}_k^T \mathbf{r}_k} \end{aligned}$$

donde

$$\theta_k = \begin{cases} 1 & \text{si } \mathbf{s}_k^T \mathbf{y}_k \geq \theta \mathbf{s}_k^T \mathbf{B}_k \mathbf{s}_k \\ \frac{(1-\theta) \mathbf{s}_k^T \mathbf{B}_k \mathbf{s}_k}{\mathbf{s}_k^T \mathbf{B}_k \mathbf{s}_k - \mathbf{s}_k^T \mathbf{y}_k} & \text{si } \mathbf{s}_k^T \mathbf{y}_k < \theta \mathbf{s}_k^T \mathbf{B}_k \mathbf{s}_k \end{cases}$$

- Si $\theta_k = 1$ entonces se obtiene la actualización BFGS.
- Si $\theta_k = 0$ entonces $\mathbf{B}_{k+1} = \mathbf{B}_k$.
- Si $0 < \theta_k < 1$ entonces se obtiene una interpolación entre \mathbf{B}_k y BFGS.

- Si $s_k^T y_k < \theta s_k^T B_k s_k$ entonces se garantiza la condición de curvatura y por tanto B_{k+1} es positiva definida, ie

$$\begin{aligned}
 s_k^T r_k &= s_k^T \left(\frac{(1 - \theta) s_k^T B_k s_k}{s_k^T B_k s_k - s_k^T y_k} y_k + \frac{\theta s_k^T B_k s_k - s_k^T y_k}{s_k^T B_k s_k - s_k^T y_k} B_k s_k \right) \\
 &= \frac{(1 - \theta) s_k^T B_k s_k}{s_k^T B_k s_k - s_k^T y_k} s_k^T y_k + \frac{\theta s_k^T B_k s_k - s_k^T y_k}{s_k^T B_k s_k - s_k^T y_k} s_k^T B_k s_k \\
 &= \frac{s_k^T B_k s_k}{s_k^T B_k s_k - s_k^T y_k} ((1 - \theta) s_k^T y_k + \theta s_k^T B_k s_k - s_k^T y_k) \\
 &= \theta \frac{s_k^T B_k s_k - s_k^T y_k}{s_k^T B_k s_k - s_k^T y_k} s_k^T B_k s_k \\
 &= \theta s_k^T B_k s_k > 0
 \end{aligned}$$

- Si $s_k^T \mathbf{y}_k < \theta s_k^T \mathbf{B}_k s_k$ entonces $0 < \theta_k < 1$.

$$\theta_k = \frac{(1 - \theta)s_k^T \mathbf{B}_k s_k}{s_k^T \mathbf{B}_k s_k - s_k^T \mathbf{y}_k}$$

Como

$$s_k^T \mathbf{y}_k < \theta s_k^T \mathbf{B}_k s_k < s_k^T \mathbf{B}_k s_k$$

entonces $s_k^T \mathbf{B}_k s_k - s_k^T \mathbf{y}_k > 0$ y por tanto $\theta_k > 0$.

- Por otro lado

$$\begin{aligned} s_k^T y_k &< \theta s_k^T \mathbf{B}_k s_k \\ 0 &< \theta s_k^T \mathbf{B}_k s_k - s_k^T y_k \\ (1 - \theta) s_k^T \mathbf{B}_k s_k &< s_k^T \mathbf{B}_k s_k - s_k^T y_k \\ \theta_k = \frac{(1 - \theta) s_k^T \mathbf{B}_k s_k}{s_k^T \mathbf{B}_k s_k - s_k^T y_k} &< 1 \end{aligned}$$

Algorithm 2 Actualizacion Damped BFGS

Dada la matriz \mathbf{B}_k simetrica y definida positiva y $\theta = 0,2$
Calcular s_k , y_k y $r_k = \theta_k y_k + (1 - \theta_k) \mathbf{B}_k s_k$ donde

$$\theta_k = \begin{cases} 1 & \text{si } s_k^T y_k \geq \theta s_k^T \mathbf{B}_k s_k \\ \frac{(1-\theta) s_k^T \mathbf{B}_k s_k}{s_k^T \mathbf{B}_k s_k - s_k^T y_k} & \text{si } s_k^T y_k < \theta s_k^T \mathbf{B}_k s_k \end{cases}$$

Actualizar

$$\mathbf{B}_{k+1} = \mathbf{B}_k - \frac{\mathbf{B}_k s_k s_k^T \mathbf{B}_k}{s_k^T \mathbf{B}_k s_k} + \frac{r_k^T r_k}{s_k^T r_k}$$
